

ĐẠI HỌC BÁCH KHOA HÀ NỘI

Khoa/Trường Công nghệ Thông tin và Truyền thông

TÀI LIỆU ĐỌC HIỂU & PHẢN BIỆN ĐỒ ÁN HỆ THỐNG GỢI Ý THỜI TRANG H&M

So sánh và phân tích chuyên sâu các mô hình:

Popularity Baseline, Matrix Factorization (MF),

Neural Collaborative Filtering (NCF) và Hybrid đa phương thức

Nhóm thực hiện: Nhóm 9

Nguyễn Thế Khải - 202400050 | Nguyễn Đăng Long - 202400057 | Phạm Gia Linh - 202416262

Giảng viên hướng dẫn: TS. Ngô Văn Linh

Hà Nội, tháng 06 năm 2026

1. Tổng Quan Dự Án & Bài Toán Implicit Feedback

Dự án tập trung giải quyết bài toán gợi ý sản phẩm thời trang được cá nhân hóa cho từng khách hàng của hãng H&M. Với dữ liệu lịch sử mua sắm khổng lồ, nhiệm vụ cốt lõi là dự đoán và lập danh sách Top-12 sản phẩm mà một khách hàng có khả năng mua cao nhất trong tuần kế tiếp (tuần kiểm thử).

Đặc trưng quan trọng của bài toán là dữ liệu tương tác implicit feedback (phản hồi ẩn). Hệ thống chỉ ghi nhận hành vi mua hàng (nhấn 1), các lượt không tương tác không mang nghĩa là khách hàng ghét sản phẩm mà chỉ đơn giản là họ chưa tiếp cận (nhấn 0). Vì vậy, quy trình huấn luyện đòi hỏi phải sử dụng kỹ thuật Negative Sampling để sinh các nhãn âm từ danh sách các mặt hàng người dùng chưa mua.

2. Lý Thuyết & Công Thức Của 4 Mô Hình Gợi Ý

2.1 Popularity-based Baseline (Mô hình gợi ý theo độ phổ biến)

Mô hình đơn giản nhất, đề xuất các mặt hàng có tần suất được mua nhiều nhất trên toàn hệ thống trong thời gian gần đây mà không cần cá nhân hóa.

$$\text{score}(i) = \text{count_train}(i)$$

Trong đó: $\text{count_train}(i)$ là số lần sản phẩm i xuất hiện trong tập huấn luyện (train set). Mặc dù đơn giản, mô hình này phản ánh cực kỳ chính xác các xu hướng thời trang ngắn hạn (mùa vụ, sự kiện bán hàng) và là đối thủ đáng gờm trên tập dữ liệu H&M.

2.2 Matrix Factorization - MF (Phân rã ma trận tương tác)

Mô hình lọc cộng tác (Collaborative Filtering) cổ điển. Nó biểu diễn cả người dùng (u) và sản phẩm (i) trong cùng một không gian ẩn (latent space) có số chiều thấp d . Điểm số tương tác được dự đoán bằng tích vô hướng của hai vector ẩn cộng thêm các hệ số chệch (biases):

$$\text{score}(u, i) = p_u * q_i + b_u + b_i$$

Trong đó: p_u là vector ẩn của người dùng u , q_i là vector ẩn của sản phẩm i . b_u và b_i là hệ số chệch (bias) của người dùng và sản phẩm nhằm hấp thụ mức độ hoạt động của user và độ phổ biến chung của item. Mô hình tối ưu hóa trực tiếp các embedding này thông qua lan truyền ngược.

2.3 Neural Collaborative Filtering - NCF (Lọc cộng tác dựa trên mạng nơ-ron)

Mô hình thay thế phép nhân tuyến tính tích vô hướng của MF bằng một kiến trúc mạng nơ-ron sâu (NeuMF) để học các tương tác phi tuyến. Mô hình duy trì hai nhánh embedding độc lập:

- Nhánh GMF (Generalized Matrix Factorization): Áp dụng tích chập từng chiều (element-wise product):

$$h_GMF = p_u_G * q_i_G$$

- Nhánh MLP (Multi-Layer Perceptron): Ghép cặp vector ẩn và truyền qua mạng truyền thẳng đa tầng để học quan hệ phi tuyến:

$$h_MLP = MLP([p_u_M; q_i_M])$$

Vector biểu diễn cuối cùng là sự kết hợp của hai nhánh và được đưa qua tầng phân loại tuyến tính:

$$\text{score}(u, i) = \text{sigmoid}(w_T * [h_GMF; h_MLP] + b)$$

2.4 Multimodal Hybrid Recommendation Model (Mô hình Lai đa phương thức)

Mô hình tiên tiến nhất trong dự án. Để giải quyết triệt để vấn đề Khởi động lạnh (Cold-start) cho người dùng mới và sản phẩm mới (ít hoặc chưa có lịch sử tương tác), mô hình kết hợp ba nguồn dữ liệu khác nhau:

1. Tín hiệu lọc cộng tác (Collaborative latent representation) học từ cấu trúc NCF backbone.
2. Đặc trưng nội dung (Metadata) của sản phẩm bao gồm nhóm hàng, màu sắc, loại hàng (m_i).
3. Đặc trưng hình ảnh (Visual features) trích xuất từ ảnh sản phẩm bằng mạng CNN ResNet-50 pretrained (v_i) với số chiều 2048.

Các tín hiệu này được ghép nối (concatenate) lại thành một vector biểu diễn chung z_{ui} :

$$z_{ui} = [h_NCF_ui ; m_i ; v_i]$$

Sau đó, z_{ui} được chuyển qua mạng nơ-ron đa tầng MLP để tính toán điểm số phù hợp cuối cùng:

$$\text{score}(u, i) = \text{MLP_hybrid}(z_{ui})$$

3. Các Metric Đánh Giá Hệ Thống Gợi Ý (Evaluation Metrics)

3.1 Mean Average Precision at 12 (MAP@12)

Metric chính được sử dụng để đánh giá hiệu năng xếp hạng của cuộc thi Kaggle H&M. Average Precision (AP) đo lường chất lượng xếp hạng của một người dùng đơn lẻ, phạt nặng nếu gợi ý đúng nằm ở vị trí thấp trong danh sách Top-12:

$$AP@12(u) = (1 / \min(|G_u|, 12)) * \sum_{k=1..12} [P@k(u) * rel_u(k)]$$

Trong đó: G_u là tập sản phẩm thực tế người dùng u mua trong tuần test. $P@k(u)$ là độ chính xác cộng dồn tại vị trí k . $rel_u(k)$ bằng 1 nếu sản phẩm ở vị trí gợi ý thứ k nằm trong G_u , ngược lại bằng 0. $MAP@12$ là trung bình cộng của $AP@12$ trên toàn bộ tập người dùng U .

3.2 Hit Rate at 12 (HR@12)

Đo lường tỷ lệ người dùng có ít nhất một sản phẩm gợi ý chính xác trong danh sách 12 sản phẩm được đề xuất:

$$HR@12 = (1 / |U|) * \sum_{u} I(R_u^{12} \text{ intersects } G_u \text{ is not empty})$$

3.3 Normalized Discounted Cumulative Gain at 12 (NDCG@12)

Đo lường chất lượng xếp hạng của danh sách gợi ý bằng cách gán trọng số giảm dần theo logarit dựa trên vị trí hiển thị:

$$DCG@12(u) = \sum_{k=1..12} [rel_u(k) / \log_2(k + 1)]$$

$NDCG@12$ là tỷ lệ giữa $DCG@12$ đạt được và $IDCG@12$ (DCG lý tưởng khi sắp xếp hoàn hảo toàn bộ sản phẩm thực tế lên đầu).

4. Hàm Mất Mát BCE Loss & Kỹ Thuật Negative Sampling

Do bài toán gợi ý thuộc dạng Implicit Feedback (chỉ quan sát được tương tác dương $y=1$), mô hình sử dụng hàm mất mát Binary Cross Entropy (BCE) để tối ưu hóa xác suất dự đoán:

$$L_{BCE} = -y * \log(p) - (1 - y) * \log(1 - p)$$

Để huấn luyện mạng hiệu quả, kỹ thuật Negative Sampling được sử dụng: với mỗi giao dịch mua thực tế ($y=1$), chúng ta lấy ngẫu nhiên 4 sản phẩm người dùng chưa từng mua trong quá khứ để làm mẫu âm ($y=0$). Việc này giúp mô hình phân biệt rõ ràng giữa các sản phẩm tiềm năng và không tiềm năng.

5. Bộ Câu Hỏi & Hướng Dẫn Trả Lời Phản Biện Hội Đồng

Hỏi: Tại sao mô hình đơn giản nhất Popularity Baseline lại đạt kết quả MAP@12 cao nhất (0.06640), vượt qua tất cả các mô hình học máy phức tạp như MF, NCF hay Hybrid?

Trả lời: Do dữ liệu kiểm thử của H&M có tính xu hướng và mùa vụ cực kỳ mạnh. Trong thời trang ngắn hạn, hành vi mua sắm tập trung rất nhiều vào một nhóm nhỏ các sản phẩm hot-trend. Số liệu thực nghiệm cho thấy Top 1000 sản phẩm phổ biến nhất đã chiếm tới gần 49.7% tổng số lượt tương tác trong tuần test. Các mô hình học máy có xu hướng overfit vào lịch sử dài hạn và gặp nhiều từ negative sampling, nên khó bắt kịp độ nhạy bén với xu hướng ngắn hạn của Popularity Baseline.

Hỏi: Tại sao mô hình Hybrid đa phương thức giàu thông tin nhất (kết hợp cả Ảnh sản phẩm từ ResNet-50 và Metadata) lại có kết quả MAP@12 (0.05325) thấp hơn mô hình phân rã ma trận MF cổ điển (0.06016)?

Trả lời: Có ba nguyên nhân chính:

- 1) Vector đặc trưng hình ảnh được trích xuất từ ResNet-50 pretrained trên tập ImageNet (chứa các nhãn vật thể chung). Vì chưa được fine-tune trực tiếp trên tập dữ liệu thời trang H&M, vector ảnh này có thể chưa tối ưu để phân biệt các chi tiết thiết kế tinh tế của quần áo.
- 2) Cấu trúc kết hợp hiện tại chỉ đơn giản là ghép nối các vector (concatenate) rồi đi qua mạng MLP chung, chưa có cơ chế gating hay attention để điều chỉnh tỷ trọng đóng góp của từng nguồn tin hiệu cho mỗi người dùng.
- 3) Tín hiệu lọc cộng tác (Collaborative) trong MF đã hấp thụ rất tốt yếu tố cá nhân hóa kèm theo độ phổ biến thông qua bias (b_u, b_i) - tín hiệu mạnh nhất để tối ưu hóa metric tổng thể.

Hỏi: Sự khác biệt giữa hàm mất mát BCE khi train và metric MAP@12 khi kiểm thử là gì? Tại sao loss giảm nhưng MAP chưa chắc tăng?

Trả lời: BCE loss là hàm mất mát dạng pointwise (xét độc lập từng cặp user-item để phân loại nhị phân), trong khi MAP@12 là một metric xếp hạng (xét thứ tự tương đối của cả danh sách gợi ý). Một mô hình có thể dự đoán xác suất tốt (BCE loss giảm) nhưng nếu nó xếp sai thứ tự của các sản phẩm thực tế (ví dụ đưa sản phẩm đúng xuống vị trí thứ 12 thay vì vị trí thứ 1), điểm MAP@12 vẫn sẽ giảm mạnh. Sự lệch pha giữa mục tiêu huấn luyện (classification) và mục tiêu đánh giá (ranking) là nguyên nhân gây ra hiện tượng này.

Hỏi: Ý nghĩa thực tế của mô hình Hybrid là gì nếu kết quả MAP của nó thấp hơn Popularity và MF?

Trả lời: Mặc dù MAP tổng thể của Hybrid thấp hơn do bị ảnh hưởng bởi xu hướng tập trung của head items, mô hình Hybrid thể hiện sức mạnh vượt trội khi phân tích theo phân khúc khách hàng và sản phẩm (Segment Analysis). Đối với nhóm sản phẩm long-tail (ít tương tác hoặc sản phẩm mới hoàn toàn), mô hình Popularity và MF không thể gợi ý chính xác do thiếu lịch sử. Hybrid lúc này phát huy vai trò của tín hiệu thị giác (ảnh) và metadata để gợi ý các sản phẩm có cùng kiểu dáng hoặc chất liệu cho người dùng có sở thích tương tự.